

Mémoire de Statistique des Assurances

Abdelaziz Oumarghad

27 avril 2026

1 Introduction

Dans un contexte de tarification en assurance non-vie, la modélisation statistique des sinistres constitue un enjeu central pour les actuaires et les gestionnaires du risque. L'objectif de ce mémoire est d'analyser un portefeuille d'assurance composé de 5 352 ménages assurés, à partir de données socio-économiques et de variables de sinistralité collectées sur l'ensemble du territoire français. Ce travail s'inscrit dans une démarche économétrique rigoureuse, mobilisant des outils issus des modèles linéaires généralisés, de l'économétrie des variables instrumentales et de l'analyse de survie.

Quatre axes de modélisation structurent ce mémoire. Le premier porte sur la modélisation de la sévérité des sinistres à travers la variable **Sinistre0**, dans une perspective de tarification *a posteriori*, avec correction de l'hétéroscédasticité et traitement d'un éventuel problème d'endogénéité. Le deuxième axe s'intéresse à la modélisation d'un sinistre secondaire présentant une masse de probabilité en zéro, ce qui nécessite une approche adaptée aux distributions mixtes. Le troisième axe traite du nombre de sinistres **NSin** via des modèles de comptage. Enfin, le quatrième axe modélise la durée de souscription **Duree** en présence de censure à droite, à l'aide de méthodes d'analyse de survie.

Conformément aux consignes, l'accent est mis sur la modélisation et l'interprétation économétrique, sans description exhaustive des données.

2 Analyse préliminaire de Sinistre0

2.1 Échelle et structure de la variable

La variable **Sinistre0** ne contient aucune valeur nulle par construction. L'examen de $\exp(\text{Sinistre0})$, dont les valeurs atteignent 6×10^{11} , exclut toute interprétation logarithmique de montant monétaire : la variable est mesurée sur une échelle normalisée propre au dataset et sera modélisée **directement sans transformation**. Son histogramme (Figure 1) révèle une distribution **bimodale**, avec un premier mode autour de 9–10 et un second autour de 17–19, suggérant deux sous-populations de risque distinctes que les covariables devront capturer.




FIGURE 1 – Analyse exploratoire de **Sinistre0** : distribution brute, exponentielle, log-transformée, et distribution conditionnelle par niveau de vie (**cs**)

2.2 Analyse graphique par covariables

Afin d'identifier les variables explicatives les plus pertinentes et d'anticiper les pathologies économétriques, nous avons examiné la distribution conditionnelle de **Sinistre0** selon trois variables catégorielles clés (Figure 2).

Catégorie socioprofessionnelle (pcs). Les boxplots par **pcs** montrent des médianes relativement proches entre groupes, oscillant entre 15 et 18. Si les cadres présentent une médiane légèrement supérieure et les ouvriers une médiane légèrement inférieure, le pouvoir discriminant de **pcs** reste limité à ce stade. En revanche, la dispersion intra-groupe est fortement hétérogène selon les catégories, ce qui constitue un premier signal d'hétéroscédasticité.

Niveau de vie (cs). C'est la variable la plus discriminante. Les ménages *aisés* présentent une médiane nettement supérieure (≈ 20) et une distribution resserrée vers les valeurs élevées, tandis que les ménages *modestes* et *moyenne inférieure* affichent des médianes basses (≈ 15 – 16) et des distributions très étalées. La variable **cs** semble ainsi capturer l'essentiel de la bimodalité observée dans la distribution marginale. Par ailleurs, l'hétérogénéité des variances conditionnelles selon **cs** renforce le diagnostic d'hétéroscédasticité.

Classe d'âge (agecat). Le boxplot par **agecat** met en évidence un **effet monotone croissant** : la médiane de **Sinistre0** augmente régulièrement de la classe 21–40 (≈ 11) à la classe 61–96 (≈ 18). Ce résultat est économétriquement cohérent : les assurés plus âgés disposent en général d'un patrimoine plus important, ce qui se traduit par des sinistres de montant plus élevé.




FIGURE 2 – Distribution de Sinistre0 selon pcs, agecat et Acompm

2.3 Conclusion de l'analyse préliminaire

Ces observations orientent la stratégie de modélisation de la façon suivante. La variable **Sinistre0** sera modélisée directement par un modèle linéaire (OLS), sans transformation. Les variables **cs** et **Acompm** constitueront les régresseurs centraux. La dispersion conditionnelle hétérogène observée graphiquement justifie de corriger l'hétéroscédasticité par l'estimateur Sandwich de White. Enfin, la corrélation potentielle entre **cs** (niveau de vie) et des facteurs de risque non observés motive un test d'endogénéité par la procédure de Blundell-Robin.

3 Modélisation de Sinistre0 : tarification a posteriori

3.1 Spécification du modèle de référence

Le modèle de référence estimé par les moindres carrés ordinaires (MCO) est le suivant :

$$\text{Sinistre0}_i = \beta_0 + \sum_k \beta_k X_{ki} + \varepsilon_i, \quad E(\varepsilon_i | X_i) = 0 \quad (1)$$

où les régresseurs candidats incluent le niveau de vie (**cs**), la classe d'âge (**agecat**), la catégorie socioprofessionnelle (**pcs**), le statut résidentiel (**Atyph**), le type d'habitat (**Ahabi**), la composition du ménage (**Acompm**) et la possession d'un véhicule (**Bauto**).

3.2 Sélection des variables

Le modèle complet à 23 degrés de liberté est comparé à un modèle parcimonieux ne retenant que **cs** et **Acompm**, selon trois critères convergents.

Un test F de significativité jointe des variables exclues (**agecat**, **pcs**, **Atyph**, **Ahabi**, **Bauto**) donne une p-valeur de 0.1284, soit largement supérieure au seuil de 5% (Figure 3). On ne peut donc pas rejeter l'hypothèse nulle que ces variables sont conjointement non significatives. Par ailleurs, le critère

d'information d'Akaike (AIC) favorise le modèle parcimonieux (23518.65 contre 23528.90), et la perte de R^2 est négligeable (0.7437 contre 0.7449). Le modèle retenu est donc :

$$\text{Sinistre0}_i = \beta_0 + \beta_1 \text{cs}_i + \beta_2 \text{Acompm}_i + \varepsilon_i \quad (2)$$

```
> # Comparer les deux modèles
> anova(mod_ols2, mod_ols) # test F de significativité jointe des variables e$
Analysis of Variance Table

Model 1: Sinistre0 ~ cs + Acompm
Model 2: Sinistre0 ~ cs + agecat + pcs + Atyph + Ahabi + Acompm + Bauto
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1     5345 25304
2     5328 25192  17    112.05 1.394 0.1284
> AIC(mod_ols, mod_ols2)
      df      AIC
mod_ols  25 23528.90
mod_ols2   8 23518.65
>
```

FIGURE 3 – Test F de comparaison des modèles complet et parcimonieux

3.3 Résultats du modèle retenu

Les résultats de l'estimation sont présentés dans la Figure 4. Le modèle explique 74.4% de la variance de Sinistre0 ($R^2 = 0.7437$, $F = 2585$, $p < 2.2 \times 10^{-16}$).

```
> mod_ols2 <- lm(Sinistre0 ~ cs + Acompm, data = dat)
> summary(mod_ols2)

Call:
lm(formula = Sinistre0 ~ cs + Acompm, data = dat)

Residuals:
    Min       1Q   Median       3Q      Max
-9.6119 -1.4611 -0.0465  1.4991  7.9302

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    19.67378    0.10528   186.868  <2e-16 ***
csModeste      -2.28185    0.11994   -19.026  <2e-16 ***
csMoyenne Inf  -1.79749    0.10452   -17.198  <2e-16 ***
csMoyenne Sup  -1.15660    0.10543   -10.970  <2e-16 ***
AcompmCouple avec enfant(s) -7.94007    0.07709  -102.998  <2e-16 ***
AcompmCouple sans enfant    0.07567    0.08246    0.918    0.359
AcompmPersonne seule    0.12710    0.09702    1.310    0.190
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.176 on 5345 degrees of freedom
Multiple R-squared:  0.7437,    Adjusted R-squared:  0.7434
F-statistic: 2585 on 6 and 5345 DF, p-value: < 2.2e-16
```

FIGURE 4 – Résultats de l'estimation MCO du modèle retenu

Deux variables structurent entièrement Sinistre0 . D'une part, le niveau de vie (cs) exerce un effet

négatif croissant par rapport à la modalité de référence “Aisé” : toutes choses égales par ailleurs, un ménage modeste déclare un sinistre inférieur de 2.28 unités. D’autre part, la modalité “Couple avec enfant(s)” se distingue radicalement des trois autres compositions de ménage, avec un écart de -7.94 unités.

Ce résultat s’explique par une hétérogénéité structurelle dans les données : comme le confirme la Figure 2 (panneau **Acompm**), les couples avec enfants présentent une moyenne de **Sinistre0** de 9.99, contre 18.01 à 18.67 pour les trois autres modalités. Cette sous-population correspond vraisemblablement à un profil de police d’assurance distinct au sein du portefeuille.

TABLE 1 – Moyenne de **Sinistre0** par composition de ménage

Composition	Moyenne Sinistre0	N
Autre ménage	18.01	1921
Couple avec enfant(s)	9.99	1379
Couple sans enfant	18.58	1293
Personne seule	18.67	759

Les modalités “Couple sans enfant” et “Personne seule” ne se distinguent pas significativement de la référence “Autre ménage” (p-valeurs respectives de 0.359 et 0.190).

3.4 Correction de l’hétéroscédasticité

En présence de deux sous-populations structurellement distinctes dans les données, l’hypothèse d’homoscédasticité $V(\varepsilon \mid X) = \sigma^2 I_m$ est susceptible d’être violée. On relâche cette hypothèse en supposant une matrice de variance-covariance des erreurs Ω quelconque, et on corrige les écarts-types par l’estimateur Sandwich de White :

$$\widehat{V}_{\text{Sandwich}}(\hat{\beta}) = (X^\top X)^{-1} \left(\sum_{i=1}^m \hat{\varepsilon}_i^2 x_i x_i^\top \right) (X^\top X)^{-1} \quad (3)$$

La comparaison des écarts-types classiques et robustes (Figure 5) montre des écarts modérés, de l’ordre de +10% sur les variables **cs**, confirmant la présence d’une hétéroscédasticité faible mais réelle. Les conclusions qualitatives du modèle sont inchangées : les variables significatives au seuil de 5% demeurent **cs** et la modalité “Couple avec enfant(s)” de **Acompm**. Le modèle final retenu est donc l’équation (2) estimée avec écarts-types robustes de White.

```

> # Correction Sandwich de White (dans le programme)
> coeftest(mod_ols2, vcov = sandwich)

t test of coefficients:

              Estimate Std. Error   t value Pr(>|t|)
(Intercept)    19.673783    0.116274   169.2019  <2e-16 ***
csModeste      -2.281850    0.127422   -17.9078  <2e-16 ***
csMoyenne Inf  -1.797492    0.116014   -15.4937  <2e-16 ***
csMoyenne Sup  -1.156599    0.117027    -9.8832  <2e-16 ***
AcompmCouple avec enfant(s) -7.940071    0.074372 -106.7618  <2e-16 ***
AcompmCouple sans enfant    0.075668    0.084405    0.8965  0.3700
AcompmPersonne seule    0.127102    0.097303    1.3062  0.1915
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> # Comparer OLS standard vs OLS corrigé
> coeftest(mod_ols2) # écarts-types OLS classiques

t test of coefficients:

              Estimate Std. Error   t value Pr(>|t|)
(Intercept)    19.673783    0.105282   186.8679  <2e-16 ***
csModeste      -2.281850    0.119936   -19.0256  <2e-16 ***
csMoyenne Inf  -1.797492    0.104518   -17.1979  <2e-16 ***
csMoyenne Sup  -1.156599    0.105428   -10.9705  <2e-16 ***
AcompmCouple avec enfant(s) -7.940071    0.077090 -102.9978  <2e-16 ***
AcompmCouple sans enfant    0.075668    0.082461    0.9176  0.3589
AcompmPersonne seule    0.127102    0.097022    1.3100  0.1902
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

FIGURE 5 – Comparaison des écarts-types MCO classiques et robustes (Sandwich de White)

3.5 Détection et correction de l'endogénéité

3.5.1 Justification économétrique

La variable **cs** (niveau de vie) est susceptible d'être endogène : elle est potentiellement corrélée avec des facteurs de risque inobservés tels que le comportement de prévention, la qualité réelle du patrimoine assuré, ou l'aversion au risque du ménage. Formellement, on suspecte $E(\mathbf{cs}_i \cdot \varepsilon_i) \neq 0$, ce qui invaliderait la consistance de l'estimateur MCO.

3.5.2 Test de Blundell-Robin

On recourt au test de Blundell-Robin pour détecter l'endogénéité avant d'engager les doubles moindres carrés. On choisit comme instrument le revenu par unité de consommation **RUC**, qui est corrélé avec le niveau de vie (**cs**) mais sans effet direct propre sur le sinistre une fois **cs** contrôlé. La première étape régresse **cs** sur **RUC** et **Acompm** :

$$\mathbf{cs}_i = \alpha_0 + \alpha_1 \mathbf{RUC}_i + \alpha_2 \mathbf{Acompm}_i + \eta_i \quad (4)$$

La statistique de Student partielle sur **RUC** est $t = -16.01$ ($F_{\text{partiel}} = 256 \gg 10$), confirmant que l'instrument est fort au sens du critère de Stock-Yogo. On récupère les résidus $\hat{\eta}_i$ et on estime le modèle augmenté :

$$\mathbf{Sinistre0}_i = \beta_0 + \beta_1 \mathbf{cs}_i + \beta_2 \mathbf{Acompm}_i + \lambda \hat{\eta}_i + u_i \quad (5)$$

Le coefficient $\hat{\lambda}$ est hautement significatif ($t = 11.96$, $p < 2 \times 10^{-16}$), ce qui conduit à rejeter $H_0 : \lambda = 0$. **L'endogénéité de cs est confirmée.** L'estimateur MCO est biaisé et inconsistant ; on doit recourir aux doubles moindres carrés (2MC).

3.5.3 Estimation par doubles moindres carrés (2MC)

L'estimateur 2MC est défini par :

$$\hat{\beta}_{2MC} = (X^\top P_V X)^{-1} X^\top P_V y, \quad P_V = V(V^\top V)^{-1} V^\top \quad (6)$$

où V contient l'instrument RUC et les variables exogènes `Acompm`. Les résultats sont présentés dans la Figure 6.

```
> mod_iv <- ivreg(Sinistre0 ~ cs + Acompm | RUC + Acompm,
+               data = dat)
Warning message:
In ivreg.fit(X, Y, Z, weights, offset, ...) :
  more regressors than instruments
> summary(mod_iv, diagnostics = TRUE)

Call:
ivreg(formula = Sinistre0 ~ cs + Acompm | RUC + Acompm, data = dat)

Residuals:
    Min       1Q   Median       3Q      Max
-9.355670 -1.488367 -0.005564  1.554353  8.186395

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      20.1493     0.6192  32.541  <2e-16 ***
csModeste        -3.7285     1.2682  -2.940  0.0033 **
csMoyenne Inf    -1.7863     1.5116  -1.182  0.2374
csMoyenne Sup    -1.8237     0.8140  -2.240  0.0251 *
AcompmCouple avec enfant(s) -8.0047     0.2048 -39.087  <2e-16 ***

Diagnostic tests:
              df1  df2 statistic p-value
Weak instruments (csModeste)      1 5347   1195.5  <2e-16 ***
Weak instruments (csMoyenne Inf)  1 5347    592.5  <2e-16 ***
Weak instruments (csMoyenne Sup)  1 5347    218.7  <2e-16 ***
Wu-Hausman                       1 5344    143.1  <2e-16 ***
Sargan                           -2   NA         NA      NA
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.242 on 5347 degrees of freedom
Multiple R-Squared: 0.7278,    Adjusted R-squared: 0.7276
Wald test: 3684 on 4 and 5347 DF, p-value: < 2.2e-16
```

FIGURE 6 – Résultats de l'estimation par doubles moindres carrés (2MC)

Le test de Wu-Hausman confirme l'endogénéité ($F = 143.1$, $p < 2 \times 10^{-16}$). Les instruments sont forts pour toutes les modalités de `cs` (F_{partiel} entre 218 et 1196). Le test de Sargan n'est pas applicable, le modèle étant exactement identifié.

TABLE 2 – Comparaison MCO et 2MC

Variable	MCO	2MC	Variation
(Constante)	19.674	20.149	+0.48
cs : Modeste	-2.282	-3.729**	-63%
cs : Moyenne Inf	-1.797	-1.786	stable (ns)
cs : Moyenne Sup	-1.157	-1.824*	-58%
Couple avec enfant(s)	-7.940	-8.005	stable

** $p < 0.01$, * $p < 0.05$, ns = non significatif

La correction de l'endogénéité révèle que le MCO **sous-estimait** l'effet du niveau de vie sur le sinistre — biais atténuateur classique en présence d'erreur de mesure sur la variable endogène. En 2MC, les ménages modestes présentent un sinistre inférieur de 3.73 unités par rapport aux ménages

aisés, contre 2.28 en MCO. La modalité `csMoyenne Inf` devient non significative en 2MC, suggérant que son effet MCO était partiellement spurieux.

4 Modélisation de `Sinistre1` : tarification a priori

4.1 Justification du choix de `Sinistre1` et de l'approche

Parmi les trois sinistres secondaires disponibles, `Sinistre1` est retenu pour les raisons suivantes. `Sinistre2` présente une proportion de zéros de 89.6% avec seulement 555 observations positives, insuffisantes pour une estimation robuste. `Sinistre3` ne présente que 33.3% de zéros, ce qui ne justifie pas un modèle avec sélection. `Sinistre1` offre une proportion de zéros de 76.3% (4085 observations censurées) avec 1267 observations positives, ce qui est adapté à un modèle Tobit.

La distribution des valeurs positives de `Sinistre1` (Figure 7) révèle une forte asymétrie à droite avec des valeurs extrêmes jusqu'à 355. La log-transformation donne une distribution plus symétrique, justifiant la spécification gaussienne du modèle Tobit. La présence d'une masse de probabilité en zéro associée à une partie continue strictement positive oriente vers une **tarification a priori** : on modélise conjointement la probabilité de déclarer un sinistre et son montant conditionnel, à partir des seules caractéristiques observables de l'assuré avant tout sinistre.




FIGURE 7 – Distribution de `Sinistre1` : valeurs brutes et log-transformées (observations positives uniquement)

4.2 Spécification du modèle Tobit

Le modèle Tobit simple suppose l'existence d'une variable latente S_1^* gaussienne :

$$S_{1i}^* = z_i^\top \beta + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad (7)$$

La variable observée S_{1i} est liée à S_{1i}^* par le mécanisme de censure à gauche en zéro :

$$S_{1i} = \begin{cases} S_{1i}^* & \text{si } S_{1i}^* > 0 \\ 0 & \text{sinon} \end{cases} \quad (8)$$

La vraisemblance combine un terme de censure (les zéros) et un terme gaussien (les positifs) :

$$\mathcal{L}(\beta, \sigma) = \prod_{S_{1i}=0} \left[1 - \Phi\left(\frac{z_i^\top \beta}{\sigma}\right) \right] \cdot \prod_{S_{1i}>0} \frac{1}{\sigma} \phi\left(\frac{S_{1i} - z_i^\top \beta}{\sigma}\right) \quad (9)$$

4.3 Sélection des variables

Un modèle complet incluant `cs`, `agecat`, `Acompm` et `Atyph` est comparé à un modèle parcimonieux excluant `cs`. Le test du rapport de vraisemblance donne $\chi^2 = 0.223$ avec 3 degrés de liberté ($p = 0.974$) : `cs` n'apporte aucune information sur `Sinistre1`. L'AIC confirme ce choix (14250.65 contre 14256.43). Le modèle retenu exclut donc `cs`.

4.4 Résultats

Les résultats du modèle Tobit retenu sont présentés dans la Figure 8. L'échelle estimée est $\hat{\sigma} = 21.04$, reflétant la forte dispersion des montants de sinistres positifs.

```
> summary(mod_tobit2)

Call:
tobit(formula = Sinistre1 ~ agecat + Acompm + Atyph, left = 0,
      data = dat)

Observations:
      Total  Left-censored  Uncensored Right-censored
      5352         4085         1267             0

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -13.06958    1.18874  -10.995  < 2e-16 ***
agecat41-50     -1.55875    1.13668   -1.371   0.1703
agecat51-60     -2.92140    1.37212   -2.129   0.0332 *
agecat61-96     -7.27625    1.36463   -5.332  9.71e-08 ***
AcompmCouple avec enfant(s) -1.28961    1.15573   -1.116   0.2645
AcompmCouple sans enfant    -2.27225    1.17634   -1.932   0.0534 .
AcompmPersonne seule       -3.27032    1.35135   -2.420   0.0155 *
AtyphNon declare    -1.94501    3.40821   -0.571   0.5682
AtyphProprietaire    -1.87046    0.84860   -2.204   0.0275 *
Log(scale)         3.04662    0.02112  144.220  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Scale: 21.04

Gaussian distribution
Number of Newton-Raphson Iterations: 4
Log-likelihood: -7115 on 10 Df
Wald-statistic: 76.12 on 8 Df, p-value: 2.9429e-13
```

FIGURE 8 – Résultats du modèle Tobit retenu pour `Sinistre1`

TABLE 3 – Coefficients du modèle Tobit pour **Sinistre1**

Variable	Estimé	Écart-type	z	p -valeur
(Constante)	-13.070	1.189	-10.995	$< 2 \times 10^{-16}$
agecat : 41-50	-1.559	1.137	-1.371	0.170
agecat : 51-60	-2.921	1.372	-2.129	0.033*
agecat : 61-96	-7.276	1.365	-5.332	$< 10^{-7***}$
Acompm : Couple avec enfant(s)	-1.290	1.156	-1.116	0.265
Acompm : Couple sans enfant	-2.272	1.176	-1.932	0.053.
Acompm : Personne seule	-3.270	1.351	-2.420	0.016*
Atyph : Non déclaré	-1.945	3.408	-0.571	0.568
Atyph : Propriétaire	-1.870	0.849	-2.204	0.028*
$\log(\hat{\sigma})$	3.047	0.021	144.22	$< 2 \times 10^{-16}$

Contrairement à **Sinistre0**, le niveau de vie (**cs**) n'a aucun effet sur **Sinistre1**, suggérant que ces deux variables mesurent des sinistres de nature différente. **Sinistre1** est structuré par l'âge et la situation résidentielle : les assurés de 61 ans et plus présentent un sinistre latent inférieur de 7.28 unités à la référence (21-40 ans), les propriétaires déclarent moins que les locataires (-1.87 unités), et les personnes seules sont moins sinistrées que les autres ménages (-3.27 unités).

5 Modélisation du nombre de sinistres NSin

5.1 Analyse préliminaire et choix du modèle

La variable **NSin** est une variable de comptage prenant des valeurs entières entre 0 et 30. Son analyse préliminaire révèle une moyenne de 4.25 et une variance de 14.54, soit un ratio de dispersion empirique de 3.42. Ce ratio largement supérieur à 1 indique une **surdispersion** : la contrainte d'équi-dispersion $E(Y_i) = V(Y_i)$ du modèle de Poisson est violée. On remarque également l'absence de la valeur 1 dans la distribution observée (Tableau 4), ce qui constitue une particularité structurelle du portefeuille.

TABLE 4 – Distribution de **NSin** (valeurs sélectionnées)

Valeur	0	2	3	4	5	6+
Effectif	1392	308	741	654	668	589

5.2 Modèle de Poisson, quasi-Poisson et Binomial Négatif

Le modèle de Poisson avec lien logarithmique spécifie :

$$\text{NSin}_i \sim \mathcal{P}(\lambda_i), \quad \log(\lambda_i) = x_i^\top \beta \quad (10)$$

avec $E(\text{NSin}_i) = V(\text{NSin}_i) = \lambda_i$. Ce modèle est inadapté à la surdispersion observée. Deux corrections sont envisagées.

Le **modèle quasi-Poisson** relâche l'équi-dispersion en supposant $V(\text{NSin}_i) = \phi \cdot \lambda_i$ avec $\phi > 1$. Les coefficients sont identiques au Poisson mais les écarts-types sont corrigés par $\sqrt{\hat{\phi}}$.

Le **modèle Binomial Négatif** (BN) modélise explicitement la surdispersion via un paramètre de mélange θ :

$$V(\text{NSin}_i) = \lambda_i + \frac{\lambda_i^2}{\theta} \quad (11)$$

Plus θ est petit, plus la surdispersion est forte. Un test du rapport de vraisemblance entre Poisson et BN donne $\chi^2 = 3769.8$ ($p < 2 \times 10^{-16}$), confirmant que le BN est significativement meilleur que le Poisson. Le paramètre estimé est $\hat{\theta} = 1.84$, confirmant une surdispersion substantielle.

Le quasi-Poisson et le BN conduisent à des conclusions qualitativement similaires, avec $\hat{\phi} = 2.54$ pour le quasi-Poisson. On retient le **modèle quasi-Poisson** comme modèle de référence pour l'interprétation, car il est directement comparable au Poisson et son paramètre de dispersion est estimable sans hypothèse paramétrique sur la distribution des effets aléatoires.

5.3 Sélection des variables

Un modèle complet incluant `cs`, `agecat`, `Acompm`, `Atyph` et `pcs` est estimé. Le test F de significativité jointe de `Atyph` donne $F = 0.048$, $p = 0.954$: cette variable est exclue. Le modèle retenu inclut `cs`, `agecat`, `Acompm` et `pcs`.

5.4 Résultats

Les résultats sont présentés dans la Figure 9.

```
> summary(mod_qpoisson2)

Call:
glm(formula = NSin ~ cs + agecat + Acompm + pcs, family = quasipoisson(link = "log"),
    data = dat)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)      1.40031    0.09141   15.319 < 2e-16
csModeste         0.10610    0.05168    2.053 0.04014
csMoyenne Inf     0.14700    0.04591    3.202 0.00137
csMoyenne Sup     0.02575    0.04554    0.565 0.57176
agecat41-50      -0.03130    0.02985   -1.049 0.29444
agecat51-60      -0.11232    0.03864   -2.907 0.00367
agecat61-96      -0.19894    0.06601   -3.014 0.00259
AcompmCouple avec enfant(s)  0.02003    0.02977    0.673 0.50108
AcompmCouple sans enfant -0.47544    0.03677  -12.930 < 2e-16
AcompmPersonne seule -1.16730    0.05376  -21.713 < 2e-16
pcsArtisans, comm., chefs d'ent.  0.15235    0.09204    1.655 0.09793
pcsAutres pers. sans activite prof.  0.21099    0.09606    2.196 0.02810
pcsCadres et prof. intellectuelles sup.  0.35214    0.08232    4.278 1.92e-05
pcsEmployes      0.22188    0.07812    2.840 0.00452
pcsOuvriers       0.20570    0.07576    2.715 0.00664
pcsProfessions intermediaires  0.30456    0.07812    3.898 9.80e-05
pcsRetraites      0.08113    0.09385    0.864 0.38739

(Intercept)      ***
csModeste         *
csMoyenne Inf     **
csMoyenne Sup
agecat41-50
agecat51-60      **
agecat61-96      **
AcompmCouple avec enfant(s)
AcompmCouple sans enfant      ***
AcompmPersonne seule      ***
pcsArtisans, comm., chefs d'ent. .
pcsAutres pers. sans activite prof. *
pcsCadres et prof. intellectuelles sup. ***
pcsEmployes      **
pcsOuvriers       **
pcsProfessions intermediaires ***
pcsRetraites
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for quasipoisson family taken to be 2.542418)

Null deviance: 20265  on 5351  degrees of freedom
Residual deviance: 16102  on 5335  degrees of freedom
AIC: NA

Number of Fisher Scoring iterations: 5
```

FIGURE 9 – Résultats du modèle quasi-Poisson retenu pour `NSin`

TABLE 5 – Coefficients significatifs du modèle quasi-Poisson ($\hat{\phi} = 2.54$) et Binomial Négatif ($\hat{\theta} = 1.84$)

Variable	$\hat{\beta}$ (QP)	$e^{\hat{\beta}}$	$\hat{\beta}$ (BN)	p -valeur (QP)
(Constante)	1.400	4.055	1.471	$< 2 \times 10^{-16}***$
cs : Modeste	+0.106	1.112	+0.052	0.040*
cs : Moyenne Inf	+0.147	1.158	+0.104	0.001**
agecat : 51-60	-0.112	0.894	-0.135	0.004**
agecat : 61-96	-0.199	0.819	-0.218	0.003**
Acompm : Couple sans enfant	-0.475	0.622	-0.492	$< 2 \times 10^{-16}***$
Acompm : Personne seule	-1.167	0.311	-1.187	$< 2 \times 10^{-16}***$
pcs : Cadres	+0.352	1.422	+0.315	$< 10^{-4}***$
pcs : Prof. intermédiaires	+0.305	1.356	+0.284	$< 10^{-4}***$
pcs : Employés	+0.222	1.248	+0.214	0.005**
pcs : Ouvriers	+0.206	1.228	+0.192	0.007**

Les deux modèles convergent vers les mêmes conclusions qualitatives, ce qui renforce la robustesse des résultats. Trois résultats méritent une attention particulière. Premièrement, l'effet du niveau de vie (**cs**) est **inversé** par rapport à **Sinistre0** : les ménages modestes déclarent 11% plus de sinistres que les ménages aisés, alors qu'ils déclarent des montants plus faibles. Ce résultat illustre la dissociation classique entre fréquence et sévérité en assurance non-vie. Deuxièmement, les personnes seules déclarent 69% moins de sinistres que la référence ($e^{-1.167} = 0.311$). Troisièmement, la catégorie socio-professionnelle (**pcs**) est ici significative, contrairement aux parties précédentes : les cadres déclarent 42% plus de sinistres que la référence.

6 Modélisation de la durée de souscription

6.1 Analyse de Kaplan-Meier

La durée de souscription **Duree** est exprimée en jours, avec un indicateur de censure à droite **censure** valant 1 lorsque le contrat est encore actif au moment de l'observation. Sur les 5352 assurés, 3307 (61.8%) sont censurés à droite. La convention R est corrigée par **event = 1 - censure**.

L'estimateur de Kaplan-Meier de la fonction de survie est :

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (12)$$

où d_i est le nombre d'événements (résiliations) et n_i le nombre d'individus à risque à l'instant t_i .




FIGURE 10 – Estimateur de Kaplan-Meier global de la durée de souscription

La médiane de survie estimée est de 1027 jours (≈ 2.8 ans), avec une borne supérieure de l'IC à 95% non estimable en raison de la forte proportion de censurés (Figure 10). La courbe révèle une chute brutale dans les 30 premiers jours : $\hat{S}(30) = 0.724$, soit 27.6% des contrats résiliés dans le premier mois. Ce phénomène traduit la présence d'une population de contrats très courts dans le portefeuille. La courbe se stabilise ensuite progressivement : $\hat{S}(365) = 0.545$ et $\hat{S}(730) = 0.502$.

L'analyse stratifiée par niveau de vie (Figure 11) révèle une séparation complète des courbes selon **cs**. Le test du log-rank confirme cette séparation ($\chi^2 = 3659$, $p < 2 \times 10^{-16}$), qui s'avère être un artefact de construction des données plutôt qu'un effet économétrique interprétable. Cette variable est donc exclue du modèle de Cox.




FIGURE 11 – Estimateur de Kaplan-Meier par niveau de vie

6.2 Modèle de Cox à risques proportionnels

Le modèle de Cox spécifie la fonction de hasard conditionnelle :

$$\lambda(t | x_i) = \lambda_0(t) \cdot \exp(x_i^\top \beta) \quad (13)$$

où $\lambda_0(t)$ est le risque de base non paramétrique et $e^{\hat{\beta}_j}$ le hazard ratio associé à la variable j . L'estimation repose sur la vraisemblance partielle de Cox, qui neutralise $\lambda_0(t)$. Les résultats complets sont disponibles en Annexe A.

TABLE 6 – Hazard ratios significatifs — modèle de Cox

Variable	$\hat{\beta}$	$e^{\hat{\beta}}$	p -valeur
agecat : 51-60	-0.268	0.765	0.002**
Acompm : Couple sans enfant	-1.797	0.166	$< 2 \times 10^{-16}$ ***
Acompm : Personne seule	-1.909	0.148	$< 2 \times 10^{-16}$ ***
Atyph : Propriétaire	-0.139	0.871	0.004**
pcs : Cadres	-3.006	0.049	$< 2 \times 10^{-16}$ ***
pcs : Employés	-1.361	0.256	$< 2 \times 10^{-16}$ ***
pcs : Prof. intermédiaires	-1.769	0.170	$< 2 \times 10^{-16}$ ***
pcs : Retraités	-1.334	0.263	$< 2 \times 10^{-16}$ ***

Le modèle présente une concordance de 0.784, indiquant un bon pouvoir discriminant. Les résultats sont économétriquement cohérents : les cadres présentent un risque de résiliation 95% inférieur à la référence ($e^{-3.006} = 0.049$), les personnes seules un risque 85% inférieur, et les propriétaires un risque 13% inférieur aux locataires.

6.3 Test de l'hypothèse de proportionnalité

Le test de Schoenfeld (`cox.zph`) rejette l'hypothèse de risques proportionnels pour l'ensemble des covariables ($\chi^2_{\text{global}} = 270.1$, $p < 2 \times 10^{-16}$). Les hazard ratios varient donc dans le temps (Figure 12), ce qui constitue une limite du modèle de Cox dans ce contexte. Un modèle à effets dépendant du temps

ou une stratification dépasse le cadre de ce travail ; cette limite est néanmoins documentée comme une piste d'amélioration.




FIGURE 12 – Résidus de Schoenfeld — test de proportionnalité des risques

7 Conclusion

Ce mémoire avait pour objectif de modéliser quatre dimensions de la sinistralité d'un portefeuille de 5352 ménages assurés, en mobilisant les outils économétriques du cours : modèle linéaire, GLM, variables instrumentales, modèles de sélection et analyse de survie.

Synthèse des résultats

La première partie a modélisé la sévérité **Sinistre0** par un modèle MCO. La sélection de variables par test F et AIC a conduit à retenir uniquement le niveau de vie (**cs**) et la composition du ménage (**Acompm**), qui expliquent conjointement 74.4% de la variance. L'hétéroscédasticité a été corrigée par l'estimateur Sandwich de White, et le test de Blundell-Robin a confirmé l'endogénéité de **cs**. L'estimation par doubles moindres carrés avec **RUC** comme instrument a révélé que le MCO sous-estimait l'effet du niveau de vie d'environ 63% pour les ménages modestes — biais atténuateur classique en présence d'hétérogénéité inobservée.

La deuxième partie a traité **Sinistre1**, variable à distribution mixte avec 76.3% de zéros. Le modèle Tobit simple, estimé par maximum de vraisemblance, a montré que ce sinistre est structuré par l'âge et le statut résidentiel — et non par le niveau de vie, contrairement à **Sinistre0**. Ce résultat illustre la complémentarité des deux approches de tarification.

La troisième partie a modélisé le nombre de sinistres **NSin** par un modèle quasi-Poisson, nécessaire en raison d'une surdispersion empirique de $\hat{\phi} = 2.54$, confirmée par la supériorité du modèle Binomial Négatif sur le Poisson ($\chi^2 = 3769.8, p < 2 \times 10^{-16}$). Le modèle retenu met en évidence une dissociation entre fréquence et sévérité : les ménages modestes déclarent davantage de sinistres mais pour des montants plus faibles.

La quatrième partie a analysé la durée de souscription par l’estimateur de Kaplan-Meier et le modèle de Cox. La médiane de survie est de 1027 jours, avec une chute brutale de 27.6% des résiliations dans le premier mois. Le modèle de Cox (concordance = 0.784) identifie la composition du ménage et la catégorie socioprofessionnelle comme les principaux déterminants du risque de résiliation.

Tableau de synthèse

TABLE 7 – Synthèse des modèles et variables structurantes

Partie	Variable	Modèle retenu	Variabes structurantes
1	Sinistre0	MCO + 2MC	cs , Acompm
2	Sinistre1	Tobit	agecat , Atyph
3	NSin	Quasi-Poisson	cs , Acompm , pcs
4	Duree	Cox	Acompm , pcs

Limites et perspectives

Plusieurs limites méritent d’être mentionnées. Premièrement, la nature exacte de **Sinistre0** — dont l’échelle normalisée n’a pas pu être interprétée en unités monétaires — constitue une incertitude sur l’interprétation économique des coefficients. Deuxièmement, l’absence de la valeur 1 dans **NSin** suggère une construction particulière de cette variable, dont l’origine n’a pas pu être documentée. Troisièmement, le test de Schoenfeld rejette l’hypothèse de risques proportionnels pour l’ensemble des covariables du modèle de Cox ($p < 2 \times 10^{-16}$), ce qui limite la validité des hazard ratios estimés sur l’ensemble de l’horizon temporel. Enfin, la séparation parfaite observée pour **cs** dans l’analyse de survie suggère une possible endogénéité structurelle entre le niveau de vie et la durée de souscription, qui mériterait une investigation approfondie.

Références

- [1] Bertail, P. (2026). *Cours de Statistique des Assurances*, Master 2 ISEFAR, Université Paris Nanterre.
- [2] Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*, 2^e éd. MIT Press.
- [3] Tobin, J. (1958). Estimation of relationships for limited dependent variables. *Econometrica*, 26(1), 24–36.
- [4] Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society, Series B*, 34(2), 187–220.
- [5] Claude (Anthropic), modèle Claude Sonnet, version utilisée en avril 2026. Assistance à la rédaction et à la vérification du code R. <https://claude.ai>

A Sorties R détaillées

A.1 Résultats complets du modèle de Cox

```
> summary(mod_cox2)
Call:
coxph(formula = surv_obj ~ agecat + Acompm + Atyph + pcs, data = dat)

n= 5352, number of events= 2045

              coef exp(coef) se(coef)      z
agecat41-50      0.10348  1.10903  0.06414  1.613
agecat51-60     -0.26786  0.76502  0.08514 -3.146
agecat61-96     -0.15421  0.85709  0.12690 -1.215
AcompmCouple avec enfant(s)  0.04045  1.04128  0.06323  0.640
AcompmCouple sans enfant   -1.79706  0.16579  0.08049 -22.328
AcompmPersonne seule      -1.90886  0.14825  0.09732 -19.613
Atyphnon declare    -0.03372  0.96684  0.18334 -0.184
AtyphProprietaire   -0.13859  0.87069  0.04785 -2.896
pcsArtisans, comm., chefs d'ent. -1.14583  0.31796  0.15105 -7.586
pcsAutres pers. sans activite prof. -0.86022  0.42307  0.14275 -6.026
pcsCadres et prof. intellectuelles sup. -3.00593  0.04949  0.18225 -16.493
pcsEmployes        -1.36138  0.25631  0.11695 -11.641
pcsOuvriers         -0.71304  0.49015  0.10786 -6.611
pcsProfessions intermediaires -1.76947  0.17042  0.12100 -14.624
pcsRetraites       -1.33412  0.26339  0.14897 -8.956

Pr(>|z|)
agecat41-50      0.10665
agecat51-60      0.00166 **
agecat61-96      0.22430
AcompmCouple avec enfant(s)  0.52236
AcompmCouple sans enfant   < 2e-16 ***
AcompmPersonne seule      < 2e-16 ***
Atyphnon declare    0.85408
AtyphProprietaire   0.00377 **
pcsArtisans, comm., chefs d'ent. 3.31e-14 ***
pcsAutres pers. sans activite prof. 1.68e-09 ***
pcsCadres et prof. intellectuelles sup. < 2e-16 ***
pcsEmployes        < 2e-16 ***
pcsOuvriers        3.83e-11 ***
pcsProfessions intermediaires < 2e-16 ***
pcsRetraites       < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

exp(coef) exp(-coef) lower .95
agecat41-50      1.10903  0.9017  0.97802
agecat51-60      0.76502  1.3072  0.64743
agecat61-96      0.85709  1.1667  0.66836
AcompmCouple avec enfant(s)  1.04128  0.9604  0.91991
AcompmCouple sans enfant   0.16579  6.0319  0.14159
AcompmPersonne seule      0.14825  6.7454  0.12250
Atyphnon declare    0.96684  1.0343  0.67499
AtyphProprietaire   0.87069  1.1486  0.79266
pcsArtisans, comm., chefs d'ent. 0.31796  3.1450  0.23648
pcsAutres pers. sans activite prof. 0.42307  2.3637  0.31982
pcsCadres et prof. intellectuelles sup. 0.04949 20.2050  0.03463
pcsEmployes        0.25631  3.9016  0.20380
pcsOuvriers        0.49015  2.0402  0.39675
pcsProfessions intermediaires 0.17042  5.8678  0.13444
pcsRetraites       0.26339  3.7967  0.19670

upper .95
agecat41-50      1.25758
agecat51-60      0.90305
agecat61-96      1.09913
AcompmCouple avec enfant(s)  1.17867
AcompmCouple sans enfant   0.19411
AcompmPersonne seule      0.17940
Atyphnon declare    1.38488
AtyphProprietaire   0.95618
pcsArtisans, comm., chefs d'ent. 0.42751
pcsAutres pers. sans activite prof. 0.55965
pcsCadres et prof. intellectuelles sup. 0.07074
pcsEmployes        0.32234
pcsOuvriers        0.60554
pcsProfessions intermediaires 0.21603
pcsRetraites       0.35270

Concordance= 0.784 (se = 0.004 )
likelihood ratio test= 2038 on 15 df, p<2e-16
Wald test           = 1660 on 15 df, p<2e-16
Score (logrank) test = 2083 on 15 df, p<2e-16
```

FIGURE 13 – Output complet du modèle de Cox (mod_cox2)

B Code R complet

```
# Libraries
library(lmtest)
library(sandwich)
library(AER)
library(survival)
library(MASS) # glm.nb for Negative Binomial

source("assurance_complet.R")

# 1. Exploration de Sinistre0
summary(dat$Sinistre0)
```

```

sum(dat$Sinistre0 == 0)

par(mfrow = c(2, 2))
hist(dat$Sinistre0, breaks = 40,
main = "Distribution brute de Sinistre0",
xlab = "Sinistre0", ylab = "Fréquence")
hist(exp(dat$Sinistre0), breaks = 40,
main = "Montants réels exp(Sinistre0)",
xlab = "Montant (€)", ylab = "Fréquence")
hist(log(dat$Sinistre0), breaks = 40,
main = "log(Sinistre0)",
xlab = "log(Sinistre0)", ylab = "Fréquence")
boxplot(Sinistre0 ~ cs, data = dat,
main = "Sinistre0 par niveau de vie",
xlab = "cs", ylab = "Sinistre0")
par(mfrow = c(1, 1))

# Cohérence de l'interprétation log-montant
cat("Médiane en euros :", exp(median(dat$Sinistre0)), "\n")
cat("Moyenne en euros :", exp(mean(dat$Sinistre0)), "\n")
cor(dat$Sinistre0, dat$reves)

# Boxplots par variable catégorielle
par(mfrow = c(1, 3))
boxplot(Sinistre0 ~ pcs, data = dat, main = "Sinistre0 ~ pcs", xlab = "pcs", ylab = "Si")
boxplot(Sinistre0 ~ agecat, data = dat, main = "Sinistre0 ~ agecat", xlab = "agecat", ylab = "Si")
boxplot(Sinistre0 ~ Acompm, data = dat, main = "Sinistre0 ~ Acompm", xlab = "Acompm", ylab = "Si")
par(mfrow = c(1, 1))

# 2. Modèles MCO
mod_ols <- lm(Sinistre0 ~ cs + agecat + pcs + Atyph + Ahabi + Acompm + Bauto,
data = dat)
summary(mod_ols)

mod_ols2 <- lm(Sinistre0 ~ cs + Acompm, data = dat)
summary(mod_ols2)

# Comparaison des deux modèles OLS
anova(mod_ols2, mod_ols)
AIC(mod_ols, mod_ols2)

# Boxplot Acompm - sauvegardé
png("box_acomp.png", width = 800, height = 600)
boxplot(Sinistre0 ~ Acompm, data = dat,
main = "Distribution de Sinistre0 par composition de ménage",
xlab = "Composition du ménage",
ylab = "Sinistre0",
col = "lightgray")
dev.off()
shell.exec("box_acomp.png")

# Écart-types OLS classiques vs robustes (White)
coeftest(mod_ols2)

```

```

coeftest(mod_ols2, vcov = sandwich)

# 3. Test d'endogénéité (Blundell-Robin)
dat$cs_num <- as.numeric(dat$cs)

# Instrument 1 : reves
cat("\n--- Première étape : instrument = reves ---\n")
first_stage_reves <- lm(cs_num ~ reves + Acompm, data = dat)
summary(first_stage_reves)
cat("F-statistic (étape 1, reves) :", summary(first_stage_reves)$fstatistic[1],
"- seuil recommandé : > 10\n")

dat$eta_hat_reves <- residuals(first_stage_reves)
mod_augmente_reves <- lm(Sinistre0 ~ cs + Acompm + eta_hat_reves, data = dat)
summary(mod_augmente_reves)

# Instrument 2 : RUC
cat("\n--- Première étape : instrument = RUC ---\n")
first_stage_RUC <- lm(cs_num ~ RUC + Acompm, data = dat)
summary(first_stage_RUC)
cat("F-statistic (étape 1, RUC) :", summary(first_stage_RUC)$fstatistic[1],
"- seuil recommandé : > 10\n")

dat$eta_hat_RUC <- residuals(first_stage_RUC)
mod_augmente_RUC <- lm(Sinistre0 ~ cs + Acompm + eta_hat_RUC, data = dat)
summary(mod_augmente_RUC)

# Instrument 3 : crevpp
dat$crevpp_num <- as.numeric(dat$crevpp)
first_stage_crevpp <- lm(cs_num ~ crevpp_num + Acompm, data = dat)
summary(first_stage_crevpp)
cat("F-statistic (étape 1, crevpp) :", summary(first_stage_crevpp)$fstatistic[1], "\n")

# 4. Régression IV (Variables Instrumentales)
mod_iv <- ivreg(Sinistre0 ~ cs + Acompm | RUC + Acompm, data = dat)
summary(mod_iv, diagnostics = TRUE)

# 5. Exploration Sinistre1 / 2 / 3
# Proportion de zéros
cat("Proportion de zéros - Sinistre1 :", mean(dat$Sinistre1 == 0), "\n")
cat("Proportion de zéros - Sinistre2 :", mean(dat$Sinistre2 == 0), "\n")
cat("Proportion de zéros - Sinistre3 :", mean(dat$Sinistre3 == 0), "\n")

# Distribution des valeurs positives
summary(dat$Sinistre1[dat$Sinistre1 > 0])
summary(dat$Sinistre2[dat$Sinistre2 > 0])
summary(dat$Sinistre3[dat$Sinistre3 > 0])

cat("N positifs - Sinistre1 :", sum(dat$Sinistre1 > 0), "\n")
cat("N positifs - Sinistre2 :", sum(dat$Sinistre2 > 0), "\n")
cat("N positifs - Sinistre3 :", sum(dat$Sinistre3 > 0), "\n")

par(mfrow = c(1, 2))

```

```

hist(dat$Sinistre1[dat$Sinistre1 > 0], breaks = 40,
main = "Sinistre1 (valeurs positives)",
xlab = "Sinistre1", ylab = "Fréquence")
hist(log(dat$Sinistre1[dat$Sinistre1 > 0]), breaks = 40,
main = "log(Sinistre1) (valeurs positives)",
xlab = "log(Sinistre1)", ylab = "Fréquence")
par(mfrow = c(1, 1))

# 6. Modèles Tobit
mod_tobit <- tobit(Sinistre1 ~ cs + agecat + Acompm + Atyph, left = 0, data = dat)
summary(mod_tobit)

mod_tobit2 <- tobit(Sinistre1 ~ agecat + Acompm + Atyph, left = 0, data = dat)
summary(mod_tobit2)

AIC(mod_tobit, mod_tobit2)
lrtest(mod_tobit2, mod_tobit)

# 7. Modèles de comptage (NSin)
summary(dat$NSin)
table(dat$NSin)
cat("Ratio de dispersion (var/mean) :", var(dat$NSin) / mean(dat$NSin), "\n")

# Poisson
mod_poisson <- glm(NSin ~ cs + agecat + Acompm + Atyph + pcs,
family = poisson(link = "log"), data = dat)
summary(mod_poisson)

# Quasi-Poisson (corrige la surdispersion)
mod_qpoisson <- glm(NSin ~ cs + agecat + Acompm + Atyph + pcs,
family = quasipoisson(link = "log"), data = dat)
summary(mod_qpoisson)
cat("Paramètre de dispersion (quasi-Poisson) :", summary(mod_qpoisson)$dispersion, "\n")

# Quasi-Poisson sans Atyph
mod_qpoisson2 <- glm(NSin ~ cs + agecat + Acompm + pcs,
family = quasipoisson(link = "log"), data = dat)
summary(mod_qpoisson2)
anova(mod_qpoisson2, mod_qpoisson, test = "F")

# Binomiale Négative - alternative à quasi-Poisson pour la surdispersion
mod_nb <- glm.nb(NSin ~ cs + agecat + Acompm + Atyph + pcs, data = dat)
summary(mod_nb)
cat("Theta (BN) :", mod_nb$theta, "- plus theta est petit, plus la surdispersion est forte\n")

# Comparaison Poisson vs BN (test du rapport de vraisemblance)
lrtest(mod_poisson, mod_nb)

# 8. Analyse de survie
summary(dat$Duree)
cat("Proportion de censurés :", mean(dat$censure), "\n")
table(dat$censure)

```

```

dat$event <- 1 - dat$censure
surv_obj <- Surv(dat$Duree, dat$event)

# Kaplan-Meier global
km_global <- survfit(surv_obj ~ 1, data = dat)
summary(km_global)$table
summary(km_global, times = c(30, 90, 180, 365, 730))

png("km_global.png", width = 800, height = 600)
plot(km_global,
main = "Kaplan-Meier - Durée de souscription",
xlab = "Durée (jours)", ylab = "S(t)",
conf.int = TRUE)
dev.off()
shell.exec("km_global.png")

# KM par niveau de vie + test du log-rank
km_cs <- survfit(surv_obj ~ cs, data = dat)
logrank_cs <- survdiff(surv_obj ~ cs, data = dat)
print(logrank_cs)
cat("p-value log-rank (cs) :", 1 - pchisq(logrank_cs$chisq, df = length(logrank_cs$n) - 1), "\n")

png("km_cs.png", width = 800, height = 600)
plot(km_cs,
main = "Kaplan-Meier par niveau de vie (cs)",
xlab = "Durée (jours)", ylab = "S(t)",
col = 1:nlevels(dat$cs), lty = 1:nlevels(dat$cs))
legend("topright", levels(dat$cs),
col = 1:nlevels(dat$cs), lty = 1:nlevels(dat$cs))
dev.off()
shell.exec("km_cs.png")

# 9. Modèle de Cox
mod_cox <- coxph(surv_obj ~ cs + agecat + Acompm + Atyph + pcs, data = dat)
summary(mod_cox)

mod_cox2 <- coxph(surv_obj ~ agecat + Acompm + Atyph + pcs, data = dat)
summary(mod_cox2)

# Test des risques proportionnels (Schoenfeld)
zph_test <- cox.zph(mod_cox2)
print(zph_test)

# Visualisation des résidus de Schoenfeld par covariable
png("cox_zph.png", width = 800, height = 600)
par(mfrow = c(2, 2))
plot(zph_test)
par(mfrow = c(1, 1))
dev.off()
shell.exec("cox_zph.png")

```